

Informe del Proyecto de Capstone en Ciencia de Datos

Predicción del aterrizaje de la primera etapa de Falcon 9

Applied Data Science Capstone - IBM

Repositorio GitHub: <https://github.com/renatopradoxmarts/spacex-capstone-data-science>

Reporte final preparado para sustentar la recolección, limpieza, análisis exploratorio, visualización interactiva y modelamiento predictivo del proyecto.

Indicador	Resultado utilizado en el informe
Registros Falcon 9 analizados	90 lanzamientos luego de retirar registros Falcon 1
Tasa global de éxito	67% aproximadamente
Lanzamientos desde CCAFS SLC-40	55 registros
Lanzamientos a órbita GEO	1 registro
Aterrizajes exitosos en drone ship	41 registros
Variables finales tras one-hot encoding	80 columnas en el dataframe de features
Muestra de prueba para ML	18 registros
Accuracy de referencia del modelo	83.33% en la evaluación de prueba

1. Resumen ejecutivo

El proyecto analiza datos históricos de lanzamientos de SpaceX Falcon 9 con el objetivo de predecir si la primera etapa del cohete aterrizará exitosamente. Este problema es relevante porque la reutilización del booster reduce costos operativos y permite estimar con mayor precisión la viabilidad económica de un lanzamiento. Para resolverlo, se construyó un flujo completo de ciencia de datos que incluye recolección mediante API, web scraping, limpieza, análisis exploratorio, visualizaciones interactivas y modelos supervisados de clasificación.

Los resultados muestran que el desempeño de aterrizaje mejora con el tiempo, que los sitios de lanzamiento presentan comportamientos distintos y que variables como masa de carga útil, órbita, sitio de lanzamiento, número de vuelos, reutilización del booster, grid fins y landing pad aportan información relevante para anticipar el resultado. En la etapa predictiva, el conjunto de prueba tuvo 18 registros y el desempeño de referencia alcanzó una precisión de 83.33%, con especial atención a los falsos positivos, es decir, casos donde el modelo predice aterrizaje exitoso cuando realmente no ocurrió.

2. Introducción y problema de negocio

SpaceX ha incrementado su ventaja competitiva al reutilizar la primera etapa de Falcon 9. En ese contexto, estimar la probabilidad de aterrizaje exitoso permite anticipar costos, evaluar riesgos y comparar lanzamientos según condiciones operativas. El problema central del proyecto consiste en construir un modelo que prediga el resultado del aterrizaje a partir de variables históricas del lanzamiento.

Elemento	Definición aplicada
Objetivo analítico	Predecir si la primera etapa de Falcon 9 aterriza exitosamente.
Variable objetivo	Class: 1 si el aterrizaje fue exitoso y 0 si no fue exitoso.
Unidad de análisis	Cada lanzamiento Falcon 9 registrado en el dataset del curso.
Uso esperado	Apoyar la evaluación de riesgo y costo asociado a nuevos lanzamientos.

3. Recopilación de datos mediante API

La primera fuente de datos provino de una respuesta JSON estática del API de SpaceX utilizada en el laboratorio del curso. La respuesta fue solicitada con GET, convertida a un dataframe mediante pandas.json_normalize y luego enriquecida con llamadas auxiliares para obtener información descriptiva de rocket, payloads, launchpad y cores. El procesamiento inicial permitió transformar identificadores en variables analíticas como BoosterVersion, PayloadMass, Orbit, LaunchSite, Outcome, Flights, GridFins, Reused, Legs, LandingPad, Block, ReusedCount, Serial, Longitude y Latitude.

Paso	Resultado
Solicitud GET	Se validó la respuesta HTTP y se normalizó el JSON.
Extracción de IDs	Se conservaron rocket, payloads, launchpad, cores, flight_number y date_utc.
Enriquecimiento	Se usaron funciones auxiliares para obtener masa, órbita, sitio, coordenadas y datos del core.
Filtro final	Se restringió el análisis a lanzamientos Falcon 9 y a fechas hasta 2020-11-13.

4. Recopilación de datos mediante web scraping

La segunda fuente de información fue la página de Wikipedia con la lista de lanzamientos Falcon 9 y Falcon Heavy. Se utilizó requests para obtener el HTML y BeautifulSoup para parsear las tablas relevantes. Luego se extrajeron encabezados y registros de las tablas wiki, controlando inconsistencias propias del scraping como referencias, anotaciones, valores faltantes y campos sin enlaces HTML.

Campo extraído	Uso en el proyecto
Flight No., Date y Time	Orden temporal y trazabilidad del lanzamiento.
Version Booster	Caracterización técnica del booster utilizado.
Launch site	Análisis comparativo entre sitios de lanzamiento.
Payload y Payload mass	Relación entre carga útil y resultado del lanzamiento.
Orbit, Customer y outcomes	Segmentación del comportamiento por destino y resultado.

5. Limpieza, preparación y etiquetas de entrenamiento

La fase de limpieza permitió convertir los datos en una estructura apta para análisis y modelamiento. Se eliminaron lanzamientos Falcon 1 para mantener consistencia con el objetivo del proyecto, se reinició la numeración de vuelos, se imputaron valores faltantes de PayloadMass con el promedio y se mantuvieron valores nulos en LandingPad cuando el aterrizaje no usó plataforma. Posteriormente, se creó la variable Class como etiqueta de entrenamiento: 0 para resultados no exitosos y 1 para aterrizajes exitosos.

Transformación	Criterio aplicado
Filtro Falcon 9	Se excluyeron registros Falcon 1.
PayloadMass	Los nulos se reemplazaron con el promedio de la columna.
LandingPad	Se conservaron valores nulos cuando no aplicaba landing pad.
Class	1 para éxito de aterrizaje y 0 para fallos o resultados no exitosos.
One-hot encoding	Orbit, LaunchSite, LandingPad y Serial se transformaron en variables dummy.

6. EDA con visualización de datos

El análisis exploratorio visual permitió evaluar relaciones entre número de vuelo, masa de carga, órbita, sitio de lanzamiento y éxito del aterrizaje. Los gráficos de dispersión ayudaron a detectar patrones por sitio y órbita, mientras que los gráficos de barras y líneas permitieron resumir tasas de éxito por categoría y evolución temporal. En general, se observó una mejora progresiva de la tasa de éxito desde los primeros años hacia 2020, lo que evidencia aprendizaje operativo y madurez tecnológica.

Visualización	Propósito
Flight Number vs Launch Site	Comparar el desempeño de cada sitio a lo largo del tiempo.
Payload Mass vs Launch Site	Evaluar cómo la carga útil se relaciona con el resultado por sitio.
Success rate by Orbit	Identificar órbitas con mayor o menor tasa de éxito.
Yearly trend	Observar la mejora anual en el aterrizaje de Falcon 9.

7. EDA con SQL

El módulo SQL complementó el análisis exploratorio mediante consultas específicas sobre sitios de lanzamiento, masa de carga, clientes, booster version, outcomes y fechas. Estas consultas permitieron validar conteos clave, obtener valores agregados y responder preguntas del negocio de manera estructurada.

Consulta / hallazgo	Resultado destacado
Sitios únicos de lanzamiento	CCAFS LC-40, KSC LC-39A, VAFB SLC-4E y CCAFS SLC-40.
Lanzamientos desde CCAFS SLC-40	55 registros.
Órbita geosynchronous / GEO	1 lanzamiento.
Aterrizajes exitosos en drone ship	41 registros.
Ranking de outcomes	Se agruparon resultados entre 2010-06-04 y 2017-03-20 en orden descendente.

8. Visualización interactiva: Folium y Plotly Dash

El mapa desarrollado con Folium permitió ubicar los sitios de lanzamiento, agregar círculos, marcadores, clusters y análisis de proximidad con costa, ciudades, ferrocarriles y carreteras. Esto aportó una lectura geoespacial del problema, mostrando que los sitios de lanzamiento se ubican estratégicamente cerca de la costa y con accesibilidad logística.

La aplicación de Plotly Dash permitió explorar interactivamente la tasa de éxito por sitio y la relación entre carga útil y resultado del lanzamiento. El dashboard facilita segmentar por launch site, revisar distribuciones de éxito/fallo y observar cómo varía el resultado según la masa del payload.

Componente	Valor analítico
Folium map	Permite analizar ubicación y proximidad de sitios de lanzamiento.
Marker Cluster	Agrupar resultados de lanzamiento y diferencia éxito/fallo.
Pie chart de Dash	Resume distribución de resultados por sitio.
Scatter plot de Dash	Muestra relación entre payload y resultado de aterrizaje.

9. Modelamiento predictivo

Para el análisis predictivo, las variables categóricas fueron transformadas mediante one-hot encoding y el dataframe final de features quedó compuesto por 80 columnas numéricas. Luego se estandarizaron los datos, se dividieron en entrenamiento y prueba con test_size de 0.2 y random_state 2, y se aplicó GridSearchCV para seleccionar hiperparámetros en Logistic Regression, Support Vector Machine, Decision Tree y K-Nearest Neighbors.

Modelo evaluado	Resultado / criterio
Logistic Regression	Modelo base interpretable para clasificación binaria.
SVM	Mejor kernel validado: sigmoid.
Decision Tree	Accuracy de prueba reportado: 83.33%.
KNN	Modelo comparativo basado en proximidad entre registros.
Muestra de prueba	18 registros.

La matriz de confusión evidenció que el principal riesgo del modelo se encuentra en los falsos positivos: predicciones de aterrizaje exitoso cuando el lanzamiento realmente no aterrizó exitosamente. En un contexto operativo, este error es importante porque puede subestimar el riesgo y afectar la estimación de costos.

10. Conclusiones y recomendaciones

El proyecto confirma que los datos históricos de lanzamientos Falcon 9 contienen patrones útiles para estimar el éxito del aterrizaje de la primera etapa. La mejora temporal de la tasa de éxito, el comportamiento diferenciado por sitio de lanzamiento, la relevancia de la carga útil y la información técnica del booster son factores clave para el análisis.

Como recomendación, el modelo debe interpretarse como una herramienta de apoyo y no como un mecanismo de decisión final. Para mejorar su robustez, sería conveniente incorporar datos más recientes, probar validación temporal, ajustar umbrales de decisión para reducir falsos positivos y enriquecer el dataset con variables climáticas, tipo de misión y condiciones operativas.

Entregable	Ubicación
Repositorio GitHub	https://github.com/renatopradoxmarts/spacex-capstone-data-science
Notebooks	API, Web Scraping, Data Wrangling, EDA, SQL, Folium, Dash y Machine Learning.
Datasets	dataset_part_1.csv, dataset_part_2.csv, dataset_part_3.csv y archivos de dashboard.
Presentación e informe	Archivos PDF finales para la entrega del capstone.