

Informe del Proyecto de Capstone en Ciencia de Datos

Predicción de aterrizaje exitoso del Falcon 9 - SpaceX

Applied Data Science Capstone | IBM

Falcon 9

Landing Prediction

GitHub del proyecto:
[URL_GITHUB_DEL_PROYECTO]

Resumen Ejecutivo

Métodos aplicados y resultados principales del proyecto.

90

registros de Falcon 9
analizados

66.7%

éxito global de aterrizaje

83.33%

mejor accuracy en prueba

41

éxitos en drone ship

Se integraron datos desde la API de SpaceX y web scraping de Wikipedia para construir una base analítica consolidada. La exploración mostró que la probabilidad de aterrizaje exitoso mejora con la experiencia acumulada y varía según sitio, órbita y carga útil.

Se compararon modelos de clasificación: Logistic Regression, SVM, Decision Tree y KNN. SVM y Decision Tree alcanzaron el mejor desempeño en prueba.

El modelo permite estimar la probabilidad de recuperación de la primera etapa y apoyar decisiones de costo/riesgo para una empresa competidora.

Introducción: contexto y problema

El caso analiza la recuperación de la primera etapa del Falcon 9 como variable clave de eficiencia.

Problema de negocio

SpaceX reduce el costo de lanzamiento al reutilizar la primera etapa del Falcon 9. Por ello, predecir si la etapa aterrizará exitosamente permite estimar mejor el costo potencial del lanzamiento y tomar decisiones más competitivas.

Objetivo analítico

Recolectar, limpiar y explorar datos de lanzamientos.
Identificar patrones asociados al éxito de aterrizaje.
Entrenar modelos de clasificación para predecir el resultado.

Pregunta guía

¿Qué factores ayudan a anticipar si la primera etapa del Falcon 9 aterrizará exitosamente?

Variable objetivo: Class

1 = aterrizaje exitoso

0 = aterrizaje no exitoso

Metodología general del proyecto

Flujo completo aplicado desde la recolección hasta la comunicación de resultados.

1

Recolección

API SpaceX + Wikipedia.

2

Preparación

Normalización, limpieza y codificación.

3

EDA

Visualizaciones + SQL.

4

Interactividad

Mapa Folium + dashboard Dash.

5

Modelado

Entrenamiento, evaluación y selección.

La metodología sigue un enfoque de ciencia de datos aplicado: definición del problema, integración de datos, análisis exploratorio, visualización, modelado y comunicación.

Cada etapa genera un insumo para la siguiente: los datos limpios alimentan el EDA, los hallazgos guían el modelado y la evaluación permite elegir el modelo final.

Los notebooks, archivos CSV y scripts del dashboard deben alojarse en GitHub para asegurar trazabilidad y reproducibilidad.

Recopilación de Datos - API de SpaceX


Extracción y normalización de información desde endpoints públicos.

Se ejecutó un GET request a la API de SpaceX para obtener datos de lanzamientos, cohetes, cargas útiles, fechas y resultados asociados.

La respuesta JSON fue convertida en una estructura tabular usando `pd.json_normalize` para facilitar el análisis posterior.

Se seleccionaron variables relevantes como `FlightNumber`, `Date`, `BoosterVersion`, `PayloadMass`, `Orbit`, `LaunchSite`, `Outcome` y `LandingPad`.

El resultado fue exportado como dataset base para limpieza y procesamiento.



Salida principal: dataset_part_1.csv / dataset_part_2.csv

GitHub Notebook: [Data Collection API.ipynb](#)
[URL_GITHUB_DEL_PROYECTO]

Recopilación de Datos - Web Scraping


Complemento de datos históricos mediante BeautifulSoup y tablas de Wikipedia.

Se consultó la página histórica de lanzamientos Falcon 9 y Falcon Heavy en Wikipedia.

Con BeautifulSoup se parseó el contenido HTML y se identificaron tablas con fechas, sitios, carga útil, órbita, cliente y resultado de misión.

Los registros extraídos fueron estructurados en un DataFrame y exportados a CSV para integrarse al flujo de análisis.

Este proceso complementó la información de la API con datos tabulares de referencia histórica.




GitHub Notebook: Data Collection with Web Scraping.ipynb
[URL_GITHUB_DEL_PROYECTO]

Metodología de Limpieza de Datos

Preparación del dataset para análisis exploratorio y modelado.

Resultado total de aterrizaje




Acciones realizadas

Tratamiento de valores faltantes: LandingPad presentó 26 valores nulos.
Estandarización de variables numéricas y categóricas para análisis posterior.
Creación de la variable objetivo Class a partir del resultado de aterrizaje.
Codificación one-hot de variables categóricas: Orbit, LaunchSite, LandingPad y Serial.
Generación del archivo de features con 76 columnas para el entrenamiento.

Resultado: dataset preparado para visualización y modelos de clasificación.

EDA con Visualización de Datos

Gráficos utilizados y propósito analítico.



Propósito de los gráficos

Dispersión: observar relación entre carga útil, número de vuelo y resultado del aterrizaje.

Barras: comparar desempeño por sitio de lanzamiento y tipo de órbita.

Tendencia temporal: evaluar si la experiencia acumulada mejora la tasa de éxito.

Los gráficos ayudaron a detectar patrones antes del modelado predictivo.

GitHub Notebook: [EDA with Data Visualization.ipynb](#)
[URL_GITHUB_DEL_PROYECTO]

EDA con SQL

Consultas utilizadas para responder preguntas clave del negocio.

Consultas realizadas

Conteo de lanzamientos por Launch_Site para identificar sitios con mayor actividad.

Cálculo de masa mínima, máxima y promedio de PAYLOAD_MASS__KG_.

Agrupación de Mission_Outcome por sitio de lanzamiento para comparar resultados.

Análisis de órbitas, clientes y evolución temporal de lanzamientos.

Uso de GROUP BY, COUNT, SUM, MIN, MAX, AVG, WHERE y ORDER BY.

Ejemplo de consulta


```
SELECT COUNT(Mission_Outcome) AS  
mission_count,  
       Launch_Site  
FROM SPACEXTBL  
GROUP BY Launch_Site;
```

```
SELECT MIN(PAYLOAD_MASS__KG_)  
FROM SPACEXTBL;
```

GitHub Notebook: EDA with SQL.ipynb
[URL_GITHUB_DEL_PROYECTO]

Análisis Visual Interactivo con Folium

Mapa con sitios de lanzamiento, marcadores y análisis de proximidad.



Elementos del mapa

Marcadores para sitios de lanzamiento y registros individuales. Círculos para resaltar áreas de referencia alrededor de cada sitio.

MarkerCluster para agrupar puntos cercanos y mejorar la lectura.

Medición de proximidad a costa, carreteras, vías férreas y zonas urbanas.


La ubicación costera y la cercanía al ecuador son factores operativos relevantes.

GitHub Notebook: Interactive Visual Analytics with Folium.ipynb
[URL_GITHUB_DEL_PROYECTO]


Dashboard Interactivo con Plotly Dash

Aplicación para explorar resultados por sitio y carga útil.

Resultado total de aterrizaje



Carga útil vs. número de vuelo



El dashboard permite seleccionar el sitio de lanzamiento mediante un Dropdown.

Incluye gráfico de pastel para comparar proporción de éxito y falla por sitio.



Incluye gráfico de dispersión de PayloadMass vs. Class para observar patrones de carga útil.

La interacción facilita encontrar diferencias entre sitios sin modificar el código base.

GitHub Script: `app.py` / `plotly_dash.py`
[[URL_GITHUB_DEL_PROYECTO](#)]

Resultados de Visualización EDA


Hallazgos principales a partir de gráficos de dispersión, barras y tendencia.



La tasa de éxito aumentó de forma importante después de los primeros años de operación.
KSC LC 39A y VAFB SLC 4E muestran las tasas de éxito más altas; CCAFS SLC 40 concentra más lanzamientos.
La carga útil no explica por sí sola el resultado; debe evaluarse junto con sitio, órbita, booster y experiencia de vuelo.

Resultados de EDA con SQL

Síntesis de hallazgos obtenidos mediante consultas estructuradas.



55

lanzamientos desde CCAFS SLC

40

350 kg

carga útil mínima

15,600 kg

carga útil máxima


GTO

órbita con mayor frecuencia


Las órbitas ES-L1, GEO, HEO y SSO alcanzan 100% de éxito en el dataset, aunque algunas tienen muy pocos registros. GTO es la órbita más frecuente y presenta un desempeño más moderado, por lo que requiere mayor atención analítica.

Resultados de Folium y Plotly Dash

Lectura espacial e interactiva de los lanzamientos.



Resultado total de aterrizaje



Los sitios de lanzamiento se ubican cerca de la costa y en latitudes favorables para operaciones espaciales.



El mapa permite evaluar proximidad a infraestructura y zonas geográficas relevantes.

El dashboard evidencia que la tasa de éxito varía por sitio de lanzamiento y que la carga útil debe interpretarse junto con otras variables.

La visualización interactiva facilita comunicar hallazgos a usuarios no técnicos.

Análisis Predictivo y Conclusión

Comparación de modelos, matriz de confusión y recomendación final.



Conclusión principal

SVM y Decision Tree alcanzaron 83.33% de accuracy en el test set.

Decision Tree ofrece una lectura más interpretable para explicar reglas y variables relevantes.

El modelo puede apoyar decisiones de costo/riesgo, pero debe actualizarse con nuevos lanzamientos y validarse con más datos.

**Mejor enfoque para comunicar:
Decision Tree por equilibrio entre
desempeño e interpretabilidad.**

GitHub Notebook: Machine Learning Prediction.ipynb
[URL_GITHUB_DEL_PROYECTO]